

TABLAS DEL ESTADO DEL ARTE — 42 ARTÍCULOS CIENTÍFICOS Q1

Tesis: Sistema web de comercio electrónico con IA para predicción del riesgo empresarial — Calzatura Vilchez
Autor: Piero Vilchez | Universidad Continental | Variables · Dimensiones · Indicadores · Instrumentos

◆ EJE 1 — TABLAS DEL ESTADO DEL ARTE

Artículo [01] — Digital transformation: A multidisciplinary reflection and research agenda

Verhoef, P.C. et al. (2021) — *Journal of Business Research*, Q1 · JIF 10.97

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Transformación Digital Empresarial	Estrategia digital	Nivel de madurez digital (escala 1–5)	Revisión sistemática de literatura Análisis bibliométrico (Scopus/WoS) Encuesta Likert 5 puntos a directivos Análisis de regresión múltiple
		Inversión en TI (% del presupuesto total)	
		N.º de plataformas digitales adoptadas	
	Modelo de negocio digital	Canales digitales activos (n.º)	
		Automatización de procesos (%)	
		Integración de ecosistemas digitales (escala)	
	Orientación al cliente digital	NPS digital (Net Promoter Score)	
		Tasa de personalización de ofertas (%)	
		Interacciones omnicanal (n.º/mes)	
Variable dependiente: Desempeño Organizacional	Eficiencia operativa	Reducción de costos operativos (%)	Revisión sistemática de literatura Análisis bibliométrico (Scopus/WoS) Encuesta Likert 5 puntos a directivos Análisis de regresión múltiple
		Tiempo de ciclo de pedido (días)	
		ROI tecnológico (%)	
	Ventaja competitiva	Cuota de mercado digital (%)	
		N.º de innovaciones lanzadas/año	
		CSAT — Satisfacción del cliente (escala 1–10)	

Artículo [02] — COVID-19 Pandemic: Shifting Digital Transformation to a High-Speed Gear in SMEs

Soto-Acosta, P. (2020) — *Information Systems Management*, Q1 · JIF 7.15

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Transformación Digital Acelerada por COVID-19	Adopción tecnológica de emergencia	Tiempo de adopción digital (días)	Análisis de caso longitudinal Entrevistas semiestructuradas a gerentes de PYMES Revisión de literatura (Scopus, WoS) Análisis estadístico descriptivo
		N.º de herramientas digitales adoptadas	
		% de procesos digitalizados durante pandemia	
	Reconfiguración del modelo de negocio	Ventas en línea / ventas totales (%)	
		Reducción de operaciones presenciales (%)	
		N.º de nuevos canales digitales habilitados	
Variable dependiente: Resiliencia y Desempeño de PYMES	Continuidad operativa	Tasa de continuidad del negocio (%)	Análisis de caso longitudinal Entrevistas semiestructuradas a gerentes de PYMES Revisión de literatura (Scopus, WoS) Análisis estadístico descriptivo
		Ingresos mantenidos vs. período pre-crisis (%)	
	Adaptación digital sostenida	Crecimiento de ventas digitales post-pandemia (%)	
		Tasa de retención de clientes digitales (%)	
		NPS post-pandemia	

Artículo [03] — Digital Innovation Management: Reinventing Innovation Management Research in a Digital World

Nambisan, S. et al. (2017) — MIS Quarterly, Q1 · JIF 12.50

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Gestión de Innovación Digital	Límites de la innovación digital	N.º de actores en el ecosistema digital	Revisión conceptual y marco integrador Análisis de casos de empresas digitales globales Revisión Scopus / IEEE Xplore / AIS
		Grado de apertura de la plataforma (escala 1–5)	
		Tasa de co-creación de valor (%)	
	Procesos de innovación digital	Velocidad de iteración (sprints/mes)	
		N.º de prototipos generados	
		Tiempo de lanzamiento al mercado (días)	
	Resultados de la innovación	N.º de nuevas funcionalidades entregadas	
		Adopción de innovación por usuarios (%)	
		Valor generado por innovación (S/.)	
Variable dependiente: Desempeño Empresarial por Innovación	Competitividad	Posición relativa en el mercado (ranking sectorial)	Revisión conceptual y marco integrador Análisis de casos de empresas digitales globales Revisión Scopus / IEEE Xplore / AIS
		N.º de innovaciones lanzadas/año	
	Sostenibilidad de la innovación	Tasa de retención de innovaciones activas (%)	
		Inversión en I+D como % de ingresos	

Artículo [04] — The digital transformation of business models in the creative industries

Li, F. (2020) — British Journal of Management, Q1 · JIF 5.57

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Transformación Digital del Modelo de Negocio	Digitalización de productos y servicios	% de oferta convertida a formato digital	Estudio de casos múltiples (caso cruzado) Entrevistas a directivos (n=24) Marcos teóricos comparativos (Value Chain) Análisis temático inductivo
		N.º de servicios digitalizados	
		Nuevos canales digitales creados	
	Plataformización del negocio	N.º de socios integrados a la plataforma	
		Ingresos generados por plataforma (% del total)	
		Tasa de crecimiento de usuarios activos (%)	
Variable dependiente: Valor Empresarial Creado y Capturado	Creación de valor	Ingresos incrementales por digitalización (%)	Estudio de casos múltiples (caso cruzado) Entrevistas a directivos (n=24) Marcos teóricos comparativos (Value Chain) Análisis temático inductivo
		ROI del modelo de negocio digital	
	Captura de valor	Margen neto del negocio digital (%)	
		Cuota de mercado ganada (%)	

Artículo [05] — Why do small and medium enterprises use social media marketing and what is the impact

Chatterjee, S. y Kumar Kar, A. (2020) — Journal of Business Research, Q1 · JIF 10.97

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Adopción de Marketing Digital en PYMEs	Factores de adopción tecnológica	Percepción de utilidad (Likert 1–5)	Encuesta cuantitativa (n=302, Likert 5) Modelado PLS-SEM (SmartPLS 3) Muestreo aleatorio estratificado Análisis de confiabilidad (α Cronbach)
		Facilidad de uso percibida (Likert 1–5)	
		Presión competitiva y social percibida	
	Intensidad de uso del canal digital	Frecuencia de publicaciones (n.º/semana)	
		Presupuesto digital (% de ventas totales)	
		N.º de plataformas sociales activas	

Variable dependiente: Desempeño Empresarial de PYMEs	Desempeño comercial	Crecimiento de ventas (%)	Encuesta cuantitativa (n=302, Likert 5) Modelado PLS-SEM (SmartPLS 3) Muestreo aleatorio estratificado Análisis de confiabilidad (α Cronbach)
		N.º de nuevos clientes captados	
		Tasa de conversión digital (%)	
	Reconocimiento y posicionamiento de marca	N.º de seguidores/fans activos	
		Engagement rate (%)	
		Alcance mensual de publicaciones	

Artículo [06] — Digital marketing: A framework, review and research agenda

Kannan, P.K. (2017) — *International Journal of Research in Marketing*, Q1 · JIF 7.20

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Estrategia de Marketing Digital	Canales y medios digitales	N.º de canales digitales activos	Revisión sistemática (meta-análisis) Marco conceptual integrador Encuesta a consumidores online Google Analytics / CRM (datos secundarios)
		Costo por lead digital — CPL (\$/.)	
		Alcance mensual (impresiones)	
	Personalización y segmentación	CTR — Click-through rate (%)	
		Tasa de apertura de emails (%)	
		Tasa de personalización de mensajes (%)	
	Analítica de marketing	ROI de campañas digitales (%)	
		CAC — Costo de adquisición de cliente (\$/.)	
		LTV — Valor de vida del cliente (\$/.)	
Variable dependiente: Comportamiento del Consumidor Digital	Intención de compra	Tasa de intención medida en encuesta (Likert)	Revisión sistemática (meta-análisis) Marco conceptual integrador Encuesta a consumidores online Google Analytics / CRM (datos secundarios)
		Tasa de conversión real (%)	
	Fidelización del cliente	Tasa de retención (%)	
		NPS	
		Frecuencia de recompra (veces/mes)	

Artículo [07] — The impact of digital transformation on the retailing value chain

Reinartz, W.; Wiegand, N. y Imschloss, M. (2019) — *IJRM*, Q1 · JIF 7.20

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Transformación Digital en Retail	Digitalización de la cadena de valor	% de procesos clave digitalizados	Análisis de cadena de valor (Porter adaptado) Revisión sistemática de literatura Entrevistas a directivos de retail (n=18) Datos de POS y CRM (análisis cuantitativo)
		N.º de integraciones vía API activas	
		Tiempo de procesamiento de pedidos (horas)	
	Integración omnicanal	N.º de canales integrados	
		Consistencia de experiencia entre canales (%)	
		Tasa de compra omnicanal (%)	
Variable dependiente: Cadena de Valor Minorista	Eficiencia operacional	Rotación de inventario (veces/año)	Análisis de cadena de valor (Porter adaptado) Revisión sistemática de literatura Entrevistas a directivos de retail (n=18) Datos de POS y CRM (análisis cuantitativo)
		Costo de fulfillment por pedido (\$/.)	
		Tiempo de entrega al cliente (días)	
	Satisfacción y lealtad del cliente	CSAT (escala 1–10)	
		Tasa de devoluciones (%)	
		NPS del canal digital	

Artículo [08] — The digitalization of retailing: An exploratory framework

Hagberg, J.; Sundstrom, M. y Egels-Zandén, N. (2016) — IJRDM, Q1 · JIF 4.50

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Digitalización del Retail	Adopción de tecnologías en el punto de venta	N.º de tecnologías digitales adoptadas	Marco exploratorio conceptual Análisis de tendencias tecnológicas (revisión de literatura) Estudio de casos de retail europeo Entrevistas semiestructuradas a gerentes
		Inversión en tecnología retail (% de ventas)	
		Nivel de madurez digital del punto de venta (escala)	
	Cambio en procesos y oferta retail	% de procesos de caja automatizados	
		N.º de SKUs disponibles en canal online	
		N.º de servicios digitales nuevos ofrecidos	
Variable dependiente: Modelo de Negocio Minorista Transformado	Propuesta de valor digital	Tasa de adopción de servicios digitales por clientes (%)	Marco exploratorio conceptual Análisis de tendencias tecnológicas (revisión de literatura) Estudio de casos de retail europeo Entrevistas semiestructuradas a gerentes
	Experiencia del cliente en tienda	Diferenciación percibida respecto a competidores (Likert)	
		Tiempo promedio de compra (minutos)	
		Satisfacción en punto de venta (CSAT)	
		Tasa de conversión en tienda física (%)	

◆ EJE 2 — TABLAS DEL ESTADO DEL ARTE

Artículo [09] — Artificial intelligence for decision making in the era of Big Data

Yuan, Y.; Edwards, J.S. y Dwivedi, Y.K. (2021) — IJIS, Q1 · JIF 9.14

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: IA para Toma de Decisiones con Big Data	Capacidades de procesamiento de datos	Volumen procesado (GB/día)	Revisión sistemática (PRISMA) Encuesta a tomadores de decisión Benchmarking de algoritmos (Python/R) Análisis de tendencias (2010–2021)
		Velocidad de análisis (registros/segundo)	
		Variedad de fuentes de datos integradas (n.º)	
	Algoritmos de IA aplicados	Accuracy del modelo (%)	
		Recall (%)	
		F1-score	
	Integración empresarial de IA	N.º de procesos asistidos por IA	
		Tasa de adopción interna (%)	
		ROI de implementación de IA (%)	
Variable dependiente: Calidad de las Decisiones Empresariales	Velocidad de decisión	Tiempo de decisión (horas)	Revisión sistemática (PRISMA) Encuesta a tomadores de decisión Benchmarking de algoritmos (Python/R) Análisis de tendencias (2010–2021)
		Ciclo análisis-acción reducido (%)	
	Precisión decisional	Tasa de error decisonal (%)	
		Reducción de riesgo operativo (%)	
		Ahorro por mejores decisiones (\$/.)	

Artículo [10] — How artificial intelligence will change the future of marketing

Davenport, T. et al. (2020) — Journal of the Academy of Marketing Science, Q1 · JIF 18.53

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Inteligencia Artificial	Personalización automática con IA	Tasa de personalización de contenidos (%)	Revisión de literatura prospectiva Análisis Delphi (rondas de expertos) Entrevistas a directores de marketing
		Relevancia de recomendaciones (CTR %)	
		Tiempo de generación de recomendación (ms)	

Aplicada al Marketing	Automatización de procesos de marketing	N.º de campañas automatizadas	(n=12) Análisis de plataformas IA comerciales
		Reducción de tiempo operativo de marketing (%)	
		ROI de campañas basadas en IA (%)	
Variable dependiente: Efectividad del Marketing Digital	Desempeño de campañas	Tasa de conversión (%)	Revisión de literatura prospectiva Análisis Delphi (rondas de expertos) Entrevistas a directores de marketing (n=12) Análisis de plataformas IA comerciales
		CAC — Costo de adquisición (S/.)	
		ROAS — Retorno en gasto publicitario	
	Experiencia y retención del cliente	NPS	
		Satisfacción con recomendaciones (Likert)	
		Tasa de retención (%)	

Artículo [11] — Organizational decision-making structures in the age of artificial intelligence

Shrestha, Y.R.; Ben-Menahem, S.M. y von Krogh, G. (2019) — AME, Q1 · JIF 9.87

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Integración de IA en Estructuras de Decisión Organizacional	Nivel de automatización decisional	% de decisiones automatizadas en procesos clave	Revisión conceptual y teórica Análisis de casos de empresas con IA (n=9) Teoría fundamentada en datos Entrevistas semiestructuradas a altos directivos
		Grado de autonomía de agentes IA (escala 1–5)	
		N.º de áreas funcionales con IA integrada	
	Rediseño organizacional para IA	N.º de roles modificados por IA	
		Reducción de capas jerárquicas de aprobación	
Variable dependiente: Desempeño Organizacional con IA	Agilidad organizacional	Tiempo promedio de aprobación reducido (%)	Revisión conceptual y teórica Análisis de casos de empresas con IA (n=9) Teoría fundamentada en datos Entrevistas semiestructuradas a altos directivos
		Tiempo de respuesta a cambios del mercado (días)	
		Tasa de adaptación a nuevas condiciones (encuesta)	
	Calidad de las decisiones	Tasa de decisiones correctas evaluadas ex-post (%)	
		Reducción de sesgos cognitivos (escala Likert)	

Artículo [12] — Big data analytics and firm performance: Effects of dynamic capabilities

Amba, S.F. et al. (2017) — IJPE, Q1 · JIF 9.83

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Análítica de Big Data	Infraestructura de datos	Capacidad de almacenamiento (TB)	Encuesta cuantitativa (n=302) PLS-SEM (SmartPLS 3) SPSS 24 para análisis factorial Prueba de confiabilidad (α de Cronbach > 0.70)
		Velocidad de procesamiento (Mbps)	
		N.º de fuentes de datos integradas	
	Capacidades analíticas dinámicas	N.º de modelos predictivos en producción	
		Cobertura analítica (% de procesos cubiertos)	
Variable dependiente: Desempeño de la Empresa	Desempeño operativo	Exactitud promedio de modelos (%)	Encuesta cuantitativa (n=302) PLS-SEM (SmartPLS 3) SPSS 24 para análisis factorial Prueba de confiabilidad (α de Cronbach > 0.70)
		Eficiencia de procesos (%)	
		Reducción de costos operativos (%)	
	Desempeño estratégico	Tiempo de ciclo reducido (%)	
		Crecimiento de ingresos (%)	
		Cuota de mercado (%)	
		ROI de inversión en tecnología (%)	

Artículo [13] — Statistical and Machine Learning forecasting methods: Concerns and ways forward

Makridakis, S.; Spiliotis, E. y Assimakopoulos, V. (2018) — PLOS ONE, Q1 · JIF 3.75

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Método de Pronóstico (Estadístico vs. Machine Learning)	Modelos estadísticos clásicos	MAE — Error Absoluto Medio	Competencia M4 (100.000 series temporales heterogéneas) Python (statsmodels, scikit-learn) R (forecast, M4comp2018) Benchmarking estadístico comparativo
		MASE — Error Absoluto Escalado Medio	
		sMAPE — Error Porcentual Absoluto Simétrico	
	Modelos de Machine Learning evaluados	RMSE — Raíz del Error Cuadrático Medio	
		Tiempo de entrenamiento (segundos)	
		Complejidad computacional (notación Big-O)	
	Configuración y ajuste del modelo	N.º de hiperparámetros optimizados	
		Tamaño del conjunto de entrenamiento (registros)	
		Horizonte de predicción (períodos futuros)	
Variable dependiente: Precisión del Pronóstico de Demanda	Exactitud del pronóstico	sMAPE (%)	Competencia M4 (100.000 series temporales heterogéneas) Python (statsmodels, scikit-learn) R (forecast, M4comp2018) Benchmarking estadístico comparativo
		MASE	
		OWA — Overall Weighted Average	
	Estabilidad y robustez del modelo	Varianza del error entre horizontes	
		Sesgo del modelo (bias)	
		Consistencia de resultados entre series	

Artículo [14] — Retail forecasting: Research and practice

Fildes, R.; Ma, S. y Kolassa, S. (2019) — International Journal of Forecasting, Q1 · JIF 7.22

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Modelos de Predicción de Demanda en Retail	Factores que determinan la demanda retail	Precio por unidad (\$/.)	Revisión sistemática de literatura (Scopus/WoS) Análisis empírico de datos de punto de venta (POS) Benchmarking de modelos (ARIMA, RF, XGBoost) Python / R para implementación
		Efecto de promociones (% de incremento de demanda)	
		Estacionalidad y efecto de calendario	
	Configuración del modelo predictivo	Horizonte de pronóstico (semanas)	
		Granularidad del modelo (SKU-tienda)	
		Datos históricos mínimos requeridos (días)	
Variable dependiente: Precisión del Pronóstico de Ventas Retail	Error de pronóstico	MASE	Revisión sistemática de literatura (Scopus/WoS) Análisis empírico de datos de punto de venta (POS) Benchmarking de modelos (ARIMA, RF, XGBoost) Python / R para implementación
		RMSE	
		Sesgo del pronóstico (%)	
	Impacto en gestión de inventario	Nivel de quiebre de stock evitado (%)	
		Exceso de inventario reducido (%)	
		Costo del error de pronóstico (\$/.período)	

Artículo [15] — Waiting for a sales renaissance in the fourth industrial revolution: Machine learning and selling

Syam, N. y Sharma, A. (2018) — Industrial Marketing Management, Q1 · JIF 8.49

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: IA y Automatización	Automatización del proceso de ventas	% de tareas de ventas automatizadas	Revisión teórica-prospectiva de literatura Análisis de tendencias industriales
		Tiempo ahorrado por vendedor (horas/semana)	
		N.º de interacciones con clientes automatizadas	

Aplicadas a Ventas	Augmentación del vendedor con IA	Tasa de adopción de herramientas IA por fuerza de ventas (%)	Entrevistas a directores comerciales (n=15) Análisis de plataformas CRM con IA (Salesforce, HubSpot)
		Mejora en tasa de cierre de ventas (%)	
		N.º de insights accionables generados por el sistema	
Variable dependiente: Desempeño de la Fuerza de Ventas	Productividad individual del vendedor	Ingresos por vendedor (\$./mes)	Revisión teórica-prospectiva de literatura Análisis de tendencias industriales Entrevistas a directores comerciales (n=15) Análisis de plataformas CRM con IA (Salesforce, HubSpot)
		N.º de cuentas gestionadas activamente	
		Tasa de retención de clientes (%)	
	Eficiencia del proceso de venta	Tiempo de ciclo de venta (días)	
		CAC — Costo de adquisición de cliente (\$./.)	
		Tasa de conversión de oportunidades (%)	

Artículo [16] — Artificial intelligence and innovation management: A review, framework, and research agenda

Haefner, N. et al. (2021) — R&D Management, Q1 · JIF 7.01

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: IA como Motor de Innovación Empresarial	Exploración de ideas asistida por IA	N.º de ideas generadas por IA por período	Revisión sistemática (PRISMA) Análisis bibliométrico (VOSviewer) Marco conceptual integrador multinivel Encuesta a gerentes de I+D+i
		Tasa de aceptación de ideas propuestas por IA (%)	
		Diversidad temática de ideas (índice de entropía)	
	Aceleración del proceso de innovación	Reducción del tiempo de desarrollo (%)	
		Reducción del costo de I+D por IA (%)	
Variable dependiente: Resultados de Innovación Empresarial	Output de innovación	N.º de ciclos de iteración reducidos	Revisión sistemática (PRISMA) Análisis bibliométrico (VOSviewer) Marco conceptual integrador multinivel Encuesta a gerentes de I+D+i
		N.º de nuevos productos lanzados/año	
		Tiempo al mercado — TTM (días)	
		Tasa de éxito del lanzamiento (%)	
	Capacidad de innovación organizacional	Nivel de madurez de capacidades IA (escala 1–5)	
		Inversión en I+D (% de ingresos)	
		N.º de patentes registradas/año	

Artículo [17] — Artificial intelligence (AI) and its implications for market knowledge in B2B marketing

Paschen, J.; Kietzmann, J. y Kietzmann, T.C. (2019) — IMM, Q1 · JIF 8.49

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: IA Aplicada al Conocimiento de Mercado B2B	Generación de conocimiento de mercado con IA	N.º de fuentes de datos externas integradas	Revisión conceptual de literatura Análisis de casos B2B con IA (n=6) Entrevistas semiestructuradas a expertos de marketing Framework inductivo de análisis temático
		Velocidad de actualización del conocimiento (horas)	
		Profundidad del insight generado (escala)	
	Capacidades predictivas del sistema IA	Precisión de predicción del comportamiento del cliente B2B (%)	
		Tiempo de respuesta del sistema de insights (ms)	
Variable dependiente: Ventaja Competitiva en Mercados B2B	Diferenciación del servicio	N.º de variables analizadas simultáneamente	Revisión conceptual de literatura Análisis de casos B2B con IA (n=6) Entrevistas semiestructuradas a expertos de marketing Framework inductivo de análisis temático
		Tasa de retención de clientes B2B (%)	
	Eficiencia comercial B2B	CES — Customer Effort Score	
		Tiempo de ciclo de ventas B2B (días)	
		Tasa de conversión de prospectos a clientes (%)	
		CAC B2B (\$./.)	

◆ EJE 3 — TABLAS DEL ESTADO DEL ARTE

Artículo [18] — Deep learning for financial applications: A survey

Ozbayoglu, A.M.; Gudelek, M.U. y Sezer, O.B. (2020) — Applied Soft Computing, Q1 · JIF 8.26

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Modelos de Deep Learning para Predicción Financiera	Arquitectura de la red neuronal profunda	N.º de capas ocultas del modelo	TensorFlow / Keras (Python) Conjuntos de datos financieros públicos (Compustat, WRDS) Validación cruzada k-fold (k=10) SHAP para interpretabilidad de predicciones
		N.º de neuronas por capa	
		Función de activación (ReLU, sigmoid, tanh)	
	Datos financieros de entrada	N.º de variables financieras utilizadas	
		Horizonte temporal de datos históricos (años)	
		Frecuencia de actualización de datos	
	Optimización del modelo	Tasa de aprendizaje (learning rate)	
		N.º de épocas de entrenamiento	
		Técnica de regularización aplicada (dropout, L2)	
Variable dependiente: Precisión en Predicción de Riesgo Financiero	Métricas de exactitud del modelo	Accuracy (%)	TensorFlow / Keras (Python) Conjuntos de datos financieros públicos (Compustat, WRDS) Validación cruzada k-fold (k=10) SHAP para interpretabilidad de predicciones
		AUC-ROC	
		F1-score	
		Precision y Recall	
	Estabilidad temporal del modelo	Variación del error por horizonte (δ accuracy)	
		Sesgo del modelo en datos fuera de muestra	

Artículo [19] — Machine learning models and bankruptcy prediction

Barboza, F.; Kimura, H. y Altman, E. (2017) — Expert Systems with Applications, Q1 · JIF 8.67

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Modelos de Machine Learning para Predicción de Quiebra	Variables financieras de entrada	Ratios de liquidez (Current Ratio, Quick Ratio)	Python (scikit-learn) Base de datos COMPUSTAT (EE.UU., 1985–2013) Matriz de confusión y curva ROC XGBoost, Random Forest, SVM
		Ratios de endeudamiento (Debt/Equity)	
		Rentabilidad (ROA, ROE, Margen neto)	
	Algoritmos de clasificación evaluados	Random Forest (n_estimators, max_depth)	
		SVM (kernel, C, gamma)	
		Boosting (XGBoost / AdaBoost)	
	Esquema de validación del modelo	Tamaño de muestra de entrenamiento (n)	
		Técnica de validación (CV k-fold vs. holdout)	
		Balance de clases (SMOTE aplicado)	
Variable dependiente: Predicción de Quiebra Empresarial	Exactitud del clasificador	Accuracy (%)	Python (scikit-learn) Base de datos COMPUSTAT (EE.UU., 1985–2013) Matriz de confusión y curva ROC XGBoost, Random Forest, SVM
		AUC-ROC	
		Especificidad (%)	
		Sensibilidad (recall) (%)	
	Ventaja sobre modelos clásicos	Mejora de AUC vs. Altman Z-score	
		Reducción del error tipo II (falsos negativos %)	
		Mejora vs. regresión logística simple	

Artículo [20] — Bankruptcy prediction using imaged financial ratios and convolutional neural networks

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Ratios Financieros como Imágenes para Redes CNN	Representación visual de datos financieros	N.º de ratios financieros convertidos a imagen	TensorFlow / Keras (Python) Pillow / OpenCV para generación de imágenes Base de datos EDGAR (SEC, EE.UU.) Validación cruzada k-fold estratificada
		Resolución de la imagen generada (píxeles × píxeles)	
		Dimensión temporal representada (años de datos)	
	Arquitectura de la CNN	N.º de capas convolucionales	
		Tamaño del kernel (filtro)	
Variable dependiente: Predicción de Quiebra Empresarial por Imagen	Exactitud del modelo CNN	N.º de filtros por capa convolucional	TensorFlow / Keras (Python) Pillow / OpenCV para generación de imágenes Base de datos EDGAR (SEC, EE.UU.) Validación cruzada k-fold estratificada
		Accuracy (%)	
		AUC-ROC	
	Comparativa con modelos tabulares clásicos	F1-score	
		Mejora de exactitud vs. Altman Z-score (%)	
		Mejora de AUC vs. regresión logística	

Artículo [21] — Corporate default predictions using machine learning: Literature review

Kim, M.J.; Cho, S.W. y Ryu, I. (2021) — Sustainability, Q1 · JIF 3.89

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Métodos de ML para Predicción de Default Empresarial	Variables predictoras utilizadas	Ratios financieros (liquidez, rentabilidad, apalancamiento)	Revisión sistemática (PRISMA, 2010–2020) Python (scikit-learn, XGBoost, LightGBM) SHAP para interpretabilidad Análisis bibliométrico VOSviewer
		Variables macroeconómicas (inflación, tasa de interés)	
		Datos alternativos (sentimiento de mercado, noticias)	
	Tipos de modelos de ML comparados	Regresión logística (baseline)	
		Random Forest y Gradient Boosting	
Variable dependiente: Precisión en Predicción de Incumplimiento	Métricas de desempeño del modelo	Redes neuronales artificiales y LSTM	Revisión sistemática (PRISMA, 2010–2020) Python (scikit-learn, XGBoost, LightGBM) SHAP para interpretabilidad Análisis bibliométrico VOSviewer
		AUC-ROC	
		Accuracy (%)	
		Recall / sensibilidad (%)	
	Importancia de características	Precision (%)	
		Feature importance (MDI)	
		Correlación de Pearson y Spearman	
		SHAP values para interpretación	

Artículo [22] — Dynamics of firm financial evolution and bankruptcy prediction

Du Jardin, P. (2021) — Expert Systems with Applications, Q1 · JIF 8.67

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Evolución Financiera Dinámica de la Empresa	Indicadores financieros dinámicos (variaciones temporales)	Variación del ROA año sobre año ($\Delta\%$)	Python (TensorFlow, Keras) Base de datos Diane (empresas francesas, n=15.000) Análisis de supervivencia (Kaplan-Meier) Validación walk-forward temporal
		Variación del ratio de liquidez (Δ)	
		Tendencia del margen operativo (pendiente)	
	Modelos predictivos de aprendizaje secuencial	LSTM — Long Short-Term Memory	
		RNN — Redes Neuronales Recurrentes	
Variable dependiente:	Exactitud de predicción longitudinal	Modelos de supervivencia (Cox, Kaplan-Meier)	Python (TensorFlow, Keras) Base de datos Diane (empresas
		AUC-ROC por horizonte (1, 2 y 3 años antes)	
		Accuracy en cada horizonte temporal	

Predicción de Quiebra con Perspectiva Dinámica	Ventaja sobre modelos estáticos	Mejora de AUC-ROC vs. modelo de corte transversal (%)	francesas, n=15.000) Análisis de supervivencia (Kaplan-Meier) Validación walk-forward temporal
		Anticipación de señal de distress financiero (años)	

Artículo [23] — Financial ratios and corporate governance indicators in bankruptcy prediction: A comprehensive study

Jiang, D. et al. (2018) — *Journal of Accounting and Public Policy*, Q1 · JIF 3.60

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Ratios Financieros e Indicadores de Gobernanza Corporativa	Ratios financieros clásicos	Liquidez corriente (Current Ratio)	Regresión logística binaria (Logit) Análisis discriminante múltiple (MDA) SPSS / Stata Base de datos COMPUSTAT / CRSP (1996–2015)
		Ratio de endeudamiento (Debt/Assets)	
		Margen neto (%)	
		ROA y ROE (%)	
	Indicadores de gobernanza corporativa	Tamaño del directorio (n.º miembros)	
		% de directores independientes	
Variable dependiente: Predicción de Quiebra Empresarial	Exactitud del modelo integrado	Separación de roles CEO-Presidente (dummy)	Regresión logística binaria (Logit) Análisis discriminante múltiple (MDA) SPSS / Stata Base de datos COMPUSTAT / CRSP (1996–2015)
		Accuracy del modelo combinado (%)	
		AUC-ROC combinado	
	Poder explicativo de las variables	Mejora vs. modelo solo con ratios financieros	
		Significancia estadística (p < 0.05) por variable	
		R² ajustado del modelo	
		Odds ratio por cada variable significativa	

Artículo [24] — Deep learning models for bankruptcy prediction using textual disclosures

Cai, F. et al. (2019) — *European Accounting Review*, Q1 · JIF 4.50

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Modelos de Deep Learning con Datos Textuales (NLP)	Procesamiento de lenguaje natural	Vocabulario del modelo (n.º de tokens únicos)	Python (NLTK, SpaCy, HuggingFace Transformers) TensorFlow / PyTorch Informes anuales 10-K de SEC EDGAR Validación cruzada estratificada
		Representación vectorial (word2vec, BERT, TF-IDF)	
		N.º de palabras procesadas por documento	
	Arquitectura del modelo de DL	Capas LSTM o Transformer utilizadas	
		N.º de épocas de entrenamiento	
		Tasa de aprendizaje (learning rate)	
Variable dependiente: Precisión en Predicción de Quiebra Textual	Exactitud del modelo basado en texto	Accuracy (%)	Python (NLTK, SpaCy, HuggingFace Transformers) TensorFlow / PyTorch Informes anuales 10-K de SEC EDGAR Validación cruzada estratificada
		AUC-ROC	
		F1-score	
	Valor incremental del texto vs. ratios	Mejora de AUC vs. modelo solo con ratios financieros	
		Información incremental aportada por el texto (%)	

Artículo [25] — Variable selection and corporate bankruptcy forecasts

Tian, S.; Yu, Y. y Guo, H. (2015) — *Journal of Banking & Finance*, Q1 · JIF 3.84

Variables	Dimensiones	Indicadores	Instrumentos
Variable	Variables financieras candidatas	Ratios de liquidez (Current Ratio, Quick Ratio)	LASSO, Ridge, Elastic Net (glmnet en

independiente: Selección de Variables para Pronóstico de Quiebra	Métodos de selección de variables	Ratios de apalancamiento (Debt/Equity)	R) Python / R para modelado COMPUSTAT (EE.UU., 1980–2010) PCA — Análisis de Componentes Principales
		Ratios de rentabilidad (ROA, ROE, Margen)	
		LASSO — Regularización L1	
		Stepwise selection (forward, backward)	
Variable dependiente: Pronóstico de Quiebra Empresarial	Exactitud del modelo con variables seleccionadas	Importancia de variables por Random Forest	LASSO, Ridge, Elastic Net (glmnet en R) Python / R para modelado COMPUSTAT (EE.UU., 1980–2010) PCA — Análisis de Componentes Principales
		AUC-ROC con subconjunto de variables	
		Accuracy (%)	
	Interpretabilidad del modelo	N.º de variables óptimas seleccionadas	
		N.º de coeficientes significativos ($p < 0.05$)	
		Variable de mayor importancia predictiva	
		Odds ratio por variable clave	

Artículo [26] — Financial ratios, discriminant analysis and the prediction of corporate bankruptcy

Altman, E.I. (1968) — *The Journal of Finance*, Q1 · JIF 7.75

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Ratios Financieros para Predicción de Quiebra (Modelo Z-score)	Ratios del modelo Z-score de Altman	X1: Capital trabajo / Activo total	Análisis discriminante múltiple (MDA) SPSS / SAS Base de datos empresas manufactureras EE.UU. (n=33 quebradas + 33 sanas) Estados financieros auditados
		X2: Utilidades retenidas / Activo total	
		X3: EBIT / Activo total	
		X4: Valor mercado patrimonio / Pasivo total	
		X5: Ventas / Activo total	
	Método de clasificación discriminante	Coeficientes de la función discriminante múltiple	
Variable dependiente: Clasificación del Riesgo de Quiebra	Exactitud de clasificación	Punto de corte $Z = 2.675$	Análisis discriminante múltiple (MDA) SPSS / SAS Base de datos empresas manufactureras EE.UU. (n=33 quebradas + 33 sanas) Estados financieros auditados
		Ponderación de cada ratio en la función	
		Tasa de acierto en muestra original (%)	
	Zonas de riesgo definidas	Tasa de acierto en muestra de validación (%)	
		Error tipo I y tipo II (%)	
		Zona segura: $Z > 2.99$	
		Zona gris: $1.81 < Z < 2.99$	
		Zona de distress: $Z < 1.81$	

Artículo [27] — Financial ratios as predictors of failure

Beaver, W.H. (1966) — *Journal of Accounting Research*, Q1 · JIF 4.87

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Ratios Financieros Univariados como Predictores de Quiebra	Ratios financieros individuales evaluados	Cash flow / Total deuda	Análisis univariado de ratios financieros Dichotomous classification test Muestra pareada (n=34 quebradas + 34 sanas, 5 años) COMPUSTAT / Moody's Industrial Manual
		Utilidad neta / Activo total	
		Deuda total / Activo total	
		Capital de trabajo / Activo total	
		Ratio de liquidez corriente	
	Horizonte temporal de predicción	1 año antes de la quiebra	
		2 años antes	
		3 años antes	
		4 años antes	

		5 años antes	
Variable dependiente: Discriminación entre Empresas Quebradas y Solventes	Poder predictivo de cada ratio	Tasa de clasificación correcta (%) por ratio	Análisis univariado de ratios financieros Dichotomous classification test Muestra pareada (n=34 quebradas + 34 sanas, 5 años) COMPUSTAT / Moody's Industrial Manual
		Error de predicción en dichotomous classification	
	Degradación de la señal temporal	Exactitud (%) del mejor ratio por horizonte	
		Ratio más estable a largo plazo	

◆ EJE 4 — TABLAS DEL ESTADO DEL ARTE

Artículo [28] — Microservices: The journey so far and challenges ahead

Jamshidi, P. et al. (2018) — IEEE Software, Q1 · JIF 4.40

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Arquitectura de Microservicios	Principios de diseño de microservicios	Granularidad del servicio (n.º de responsabilidades)	Revisión sistemática de literatura (IEEE/ACM) Análisis de 14 casos de sistemas en producción Docker / Kubernetes API Gateway (Kong, NGINX, AWS API GW)
		Independencia de despliegue (escala 1–5)	
		Protocolo de comunicación inter-servicio (REST, gRPC)	
	Retos de implementación	Latencia de comunicación inter-servicio (ms)	
		Complejidad de orquestación (n.º de servicios)	
Variable dependiente: Desempeño del Sistema Distribuido	Escalabilidad del sistema	Consistencia eventual de datos (CAP theorem)	Revisión sistemática de literatura (IEEE/ACM) Análisis de 14 casos de sistemas en producción Docker / Kubernetes API Gateway (Kong, NGINX, AWS API GW)
		Tiempo de escalado horizontal (segundos)	
		Recursos adicionales por instancia (CPU %, RAM GB)	
	Mantenibilidad del sistema	N.º de instancias simultáneas soportadas	
		Tiempo de despliegue de actualización (minutos)	
		Cobertura de pruebas automatizadas (%)	
		Tasa de fallos en pipeline de CI/CD (%)	

Artículo [29] — Large-scale machine learning systems in real-world industrial settings

Swakatare, L.E. et al. (2019) — ICSE Workshops (IEEE), Q1

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Sistemas de ML a Gran Escala en Producción Industrial	Escalabilidad del pipeline ML	Volumen de datos procesados (GB/hora)	MLOps (MLflow, Kubeflow) Monitoreo de datos (Evidently AI, WhyLabs) Docker / Kubernetes Entrevistas a ingenieros de ML en producción (n=8)
		Tiempo de reentrenamiento del modelo (horas)	
		N.º de modelos ML en producción simultánea	
	Confiabilidad del sistema ML	Uptime del sistema (%)	
		Tasa de fallos de predicción en producción (%)	
		MTTR — Tiempo medio de recuperación ante fallo	
Variable dependiente: Calidad del Sistema ML en Producción	Precisión en producción	Delta de accuracy (drift del modelo)	MLOps (MLflow, Kubeflow) Monitoreo de datos (Evidently AI, WhyLabs) Docker / Kubernetes Entrevistas a ingenieros de ML en producción (n=8)
		Degradación de F1-score por período	
		Frecuencia de reentrenamiento necesario (días)	
	Eficiencia operativa del sistema	Costo de inferencia (\$/. por 1000 predicciones)	
		Latencia de predicción p95 (ms)	
		Utilización de recursos (CPU %, RAM %)	

Artículo [30] — Predicting risk through artificial intelligence based on machine learning algorithms

Khalid, U. et al. (2022) — Scientific Programming (Hindawi/Wiley), Q1 · JIF 1.89

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Algoritmos de ML para Predicción de Riesgo Empresarial	Variables de entrada al modelo	Indicadores financieros históricos (n.º)	Python (scikit-learn, XGBoost) Validación cruzada k-fold (k=10) SHAP para interpretabilidad de predicciones Dataset de PYMEs regionales (Perú/Latinoamérica)
		Datos históricos de ventas (períodos mínimos)	
		Variables macroeconómicas relevantes	
	Algoritmos de ML evaluados y comparados	Random Forest Classifier / Regressor	
		Gradient Boosting (XGBoost, LightGBM)	
		K-Nearest Neighbors (KNN) y Naive Bayes	
Variable dependiente: Índice de Riesgo Empresarial Predicho	Exactitud de la predicción de riesgo	Accuracy (%)	Python (scikit-learn, XGBoost) Validación cruzada k-fold (k=10) SHAP para interpretabilidad de predicciones Dataset de PYMEs regionales (Perú/Latinoamérica)
		AUC-ROC	
		MAE — Error Absoluto Medio	
	Comparativa entre algoritmos	Mejor algoritmo por métrica de evaluación	
		Tiempo de entrenamiento (segundos)	
		Robustez ante datos faltantes o ruidosos	

Artículo [31] — Deep learning with long short-term memory networks for financial market predictions

Fischer, T. y Krauss, C. (2018) — EJOR, Q1 · JIF 6.37

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Redes LSTM para Predicción de Series Temporales Financieras	Arquitectura de la red LSTM	N.º de capas LSTM apiladas	Python (TensorFlow / Keras) S&P 500 (500 acciones, 1992–2015) Validación walk-forward temporal Métricas financieras (Sharpe ratio, Drawdown)
		N.º de unidades ocultas por capa	
		Longitud de la ventana temporal de entrada (días)	
	Datos históricos de entrenamiento	N.º de variables de entrada (features)	
		Período histórico utilizado para entrenamiento (años)	
		Frecuencia de los datos (diaria, semanal, mensual)	
Variable dependiente: Precisión en Predicción de Series Temporales	Exactitud predictiva del modelo	Accuracy de dirección de movimiento (%)	Python (TensorFlow / Keras) S&P 500 (500 acciones, 1992–2015) Validación walk-forward temporal Métricas financieras (Sharpe ratio, Drawdown)
		Sharpe ratio del portafolio resultante	
		RMSE en datos fuera de muestra	
	Comparativa con benchmarks clásicos	Mejora vs. Random Walk (% de accuracy)	
		Mejora vs. regresión logística (Δ AUC)	
		Retorno acumulado del modelo vs. buy-and-hold (%)	

Artículo [32] — Challenges in deploying machine learning: A survey of case studies

Paleyes, A.; Urma, R.G. y Lawrence, N.D. (2022) — ACM Computing Surveys, Q1 · JIF 16.60

Variables	Dimensiones	Indicadores	Instrumentos	
Variable independiente: Desafíos en el Despliegue de Modelos ML en Producción	Preparación y calidad de datos	% de datos válidos en producción	Revisión sistemática de 209 casos reales (PRISMA) MLflow / Kubeflow para MLOps Taxonomía de desafíos (categorización cualitativa) Docker / Kubernetes en producción	
		Tiempo de limpieza y preprocesamiento (horas)		
		N.º de fuentes de datos integradas al pipeline		
	Despliegue e integración del modelo	Tiempo de despliegue del modelo (horas)		
		N.º de integraciones API requeridas		
		Compatibilidad con sistemas legados existentes		

	Monitoreo y mantenimiento en producción	Frecuencia de reentrenamiento (días) Delta de accuracy detectado (data drift) N.º de alertas automatizadas configuradas	
Variable dependiente: Éxito del Despliegue ML en Entornos Reales	Fiabilidad del sistema en producción	Uptime del modelo (%) Tasa de predicciones fallidas o erróneas (%) MTTR ante incidentes de producción (horas)	Revisión sistemática de 209 casos reales (PRISMA) MLflow / Kubeflow para MLOps Taxonomía de desafíos (categorización cualitativa)
	Adopción real por usuarios del negocio	Tasa de uso efectivo del sistema ML (%) Satisfacción de usuarios internos (Likert 1–5) N.º de decisiones asistidas por ML/semana	Docker / Kubernetes en producción

Artículo [33] — Software engineering for AI-based systems: A survey

Martínez-Fernández, S. et al. (2022) — ACM TOSEM, Q1 · JIF 6.00

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Ingeniería de Software para Sistemas Basados en IA	Prácticas de ingeniería de software adaptadas a IA	N.º de prácticas de SE adaptadas para componentes ML	Revisión sistemática SLR (106 estudios, 2014–2021) Análisis temático cualitativo SonarQube para métricas de calidad de código GitHub / GitLab para datos de repositorios
		Cobertura de pruebas de componentes IA (%)	
		Nivel de documentación de requisitos de IA (escala)	
	Calidad intrínseca del software con IA	Deuda técnica de módulos IA (horas estimadas)	
		N.º de defectos detectados por release	
		Tiempo de refactorización del código IA (horas)	
	Proceso de desarrollo iterativo con IA	Duración del ciclo de experimento (días)	
		N.º de experimentos por iteración de desarrollo	
		Tasa de experimentos que avanzan a producción (%)	
Variable dependiente: Calidad del Sistema de Software con IA	Fiabilidad del sistema	MTBF — Tiempo medio entre fallos (días)	Revisión sistemática SLR (106 estudios, 2014–2021) Análisis temático cualitativo SonarQube para métricas de calidad de código GitHub / GitLab para datos de repositorios
		Tasa de fallos en producción (%)	
		N.º de incidentes críticos por mes	
	Mantenibilidad y evolución	Tiempo para incorporar nueva funcionalidad ML (días)	
		Complejidad ciclomática del código IA (McCabe)	
		Esfuerzo de mantenimiento mensual (horas)	

Artículo [34] — Understanding and addressing quality attributes of microservices architecture: A systematic mapping study

Li, S. et al. (2021) — Information and Software Technology, Q1 · JIF 3.86

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Atributos de Calidad en Arquitectura de Microservicios	Atributos de calidad evaluados (ISO/IEC 25010)	Escalabilidad: horizontal y vertical	Systematic Mapping Study (SMS) — 60 estudios primarios Docker / Kubernetes en entornos de prueba Prometheus + Grafana para monitoreo Análisis bibliométrico de ACM DL / IEEE Xplore
		Disponibilidad: uptime (%)	
		Rendimiento: latencia (ms) y throughput (RPS)	
	Patrones y estrategias de solución aplicadas	N.º de patrones aplicados (circuit breaker, saga, CQRS)	
		N.º de técnicas de monitoreo implementadas	
		Frecuencia de despliegue (veces/semana — CI/CD)	
Variable dependiente: Desempeño de la	Eficiencia del sistema	Latencia de API p95 (ms)	Systematic Mapping Study (SMS) — 60 estudios primarios Docker / Kubernetes en entornos de
		Throughput máximo (requests/segundo)	
		Tasa de errores de API 5xx (%)	

Arquitectura de Microservicios	Mantenibilidad del sistema distribuido	MTTR — Tiempo medio de resolución de incidentes	prueba Prometheus + Grafana para monitoreo Análisis bibliométrico de ACM DL / IEEE Xplore
		Cobertura de pruebas de integración (%)	
		Deuda técnica acumulada (horas estimadas)	

◆ EJE 5 — TABLAS DEL ESTADO DEL ARTE

Artículo [35] — Random forests

Breiman, L. (2001) — *Machine Learning*, Q1 · JIF 7.40

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Algoritmo Random Forest (Ensamble de Árboles de Decisión)	Hiperparámetros del algoritmo	N.º de árboles del bosque (n_estimators)	Python (scikit-learn — RandomForestClassifier/Regressor) MATLAB (TreeBagger) Validación cruzada k-fold Curvas de aprendizaje y de error vs. n_estimators
		Profundidad máxima de árbol (max_depth)	
		N.º de variables por división (max_features)	
	Proceso de ensemble por bagging	Técnica de muestreo con reemplazo (bootstrapping)	
		Agregación de predicciones (votación / promedio)	
		Semilla aleatoria (random_state) para reproducibilidad	
	Medición de importancia de variables	Mean Decrease Impurity — MDI	
		Mean Decrease Accuracy — MDA	
		SHAP values (análisis post-hoc)	
Variable dependiente: Exactitud y Robustez del Modelo Predictivo	Exactitud de clasificación y regresión	OOB Error — Error fuera de bolsa (%)	Python (scikit-learn — RandomForestClassifier/Regressor) MATLAB (TreeBagger) Validación cruzada k-fold Curvas de aprendizaje y de error vs. n_estimators
		Accuracy en clasificación (%)	
		RMSE en tareas de regresión	
	Robustez ante sobreajuste (overfitting)	Generalización en datos no vistos (test set)	
		Balance bias-variance del modelo	
		Estabilidad del error vs. n_estimators (curva)	

Artículo [36] — A decade of agile methodologies: Towards explaining agile software development

Dingsøyr, T. et al. (2012) — *Journal of Systems and Software*, Q1 · JIF 4.34

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Metodologías Ágiles de Desarrollo de Software	Prácticas ágiles adoptadas	N.º de ceremonias Scrum implementadas (daily, retro, review)	Revisión sistemática de literatura (2000–2010) Análisis bibliométrico Encuesta a equipos ágiles (n=109 proyectos) Jira / Trello para métricas de sprints
		Duración del sprint (semanas)	
		Tasa de adopción de TDD — Test-Driven Development (%)	
	Factores contextuales del equipo	Tamaño del equipo (n.º de integrantes)	
		Experiencia en metodologías ágiles (años)	
		Distribución geográfica del equipo (local/remoto)	
Variable dependiente: Desempeño del Proyecto de Software	Productividad del equipo	Velocidad del equipo (story points/sprint)	Revisión sistemática de literatura (2000–2010) Análisis bibliométrico Encuesta a equipos ágiles (n=109 proyectos) Jira / Trello para métricas de sprints
		Tasa de completitud de sprints (%)	
		Déficit de entrega por sprint (%)	
	Calidad del software entregado	N.º de defectos detectados por sprint	
		Cobertura de pruebas unitarias (%)	
		Deuda técnica acumulada (horas)	

Artículo [37] — Predicting sprint performance for agile software development using machine learning

Salgonde, O. y Chari, K. (2021) — Information Systems Management, Q1 · JIF 7.15

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Variables de Entrada para Predicción del Desempeño de Sprints	Datos históricos del sprint	Velocidad promedio histórica (story points/sprint)	Python (scikit-learn) Jira / Azure DevOps (datos históricos de sprints reales) Validación cruzada k-fold SMOTE para balanceo de clases
		N.º de items en el product backlog	
		Capacidad del equipo disponible (horas-persona)	
	Modelos de ML aplicados al sprint	Regresión lineal múltiple (baseline)	
		Random Forest Regressor	
		XGBoost Regressor (gradient boosting)	
Variable dependiente: Desempeño Predicho del Sprint	Exactitud de la predicción	RMSE — Raíz del Error Cuadrático Medio	Python (scikit-learn) Jira / Azure DevOps (datos históricos de sprints reales) Validación cruzada k-fold SMOTE para balanceo de clases
		MAE — Error Absoluto Medio	
		R² — Coeficiente de determinación	
	Utilidad práctica del modelo	Reducción del déficit de entrega del sprint (%)	
		% de sprints con predicción dentro del margen ±10%	
		Tiempo ahorrado en planificación (horas/sprint)	

Artículo [38] — Hybrid software development approaches in practice: A European perspective

Kuhrmann, M. et al. (2018) — IEEE Software, Q1 · JIF 4.40

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Enfoque Híbrido de Desarrollo (Ágil + Tradicional Planificado)	Configuración del proceso híbrido	% de prácticas ágiles adoptadas en el proceso	Encuesta a organizaciones europeas (n=732 respuestas válidas) Análisis estadístico descriptivo y factorial Clustering (k-means) de perfiles de proceso R / SPSS para análisis multivariado
		% de prácticas tradicionales (waterfall) mantenidas	
		N.º de fases formales definidas	
	Contexto organizacional de aplicación	Tamaño de la organización (n.º de empleados)	
		Dominio de la aplicación desarrollada (sector)	
		N.º de años de experiencia con enfoques híbridos	
Variable dependiente: Efectividad del Proceso de Desarrollo Híbrido	Éxito del proyecto	Entrega en plazo (% de proyectos a tiempo)	Encuesta a organizaciones europeas (n=732 respuestas válidas) Análisis estadístico descriptivo y factorial Clustering (k-means) de perfiles de proceso R / SPSS para análisis multivariado
		Desviación de presupuesto (%)	
		Satisfacción del cliente con el producto (Likert)	
	Flexibilidad y control del proceso	Capacidad de respuesta a cambios (escala 1–5)	
		Nivel de documentación generada (escala)	
		Tasa de riesgos identificados y mitigados (%)	

Artículo [39] — Prescriptive analytics: Literature review and research challenges

Lepenioti, K. et al. (2020) — International Journal of Information Management, Q1 · JIF 18.70

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Análítica Prescriptiva para Optimización de	Tipos de técnicas de analítica prescriptiva	Optimización matemática (PL, PNL, algoritmos evolutivos)	Revisión sistemática (PRISMA) — 209 publicaciones (Scopus/WoS) Taxonomía de técnicas (categorización inductiva)
		Simulación (Monte Carlo, Discrete Event Simulation — DES)	
		Reglas de negocio y sistemas expertos basados en IA	
	Nivel de automatización de la	Grado de autonomía del sistema (escala 1–5)	

Decisiones	prescripción	N.° de decisiones prescritas automáticamente por período	Python / IBM CPLEX para optimización Framework de madurez de analítica prescriptiva
		Tiempo de implementación de la prescripción (ms)	
	Calidad de los datos de entrada	Compleitud de los datos disponibles (%)	
		Frescura/lag de los datos (horas de retraso)	
		N.° de fuentes de datos integradas al modelo	
Variable dependiente: Valor de las Decisiones Prescritas por el Sistema	Calidad y aceptación de la prescripción	Tasa de adopción de prescripciones por usuarios (%)	Revisión sistemática (PRISMA) — 209 publicaciones (Scopus/WoS) Taxonomía de técnicas (categorización inductiva) Python / IBM CPLEX para optimización Framework de madurez de analítica prescriptiva
		Mejora de KPIs objetivo tras implementar prescripción (%)	
		ROI de las decisiones tomadas con prescripción (%)	
	Eficiencia operativa generada	Reducción de costos por optimización (%)	
		Reducción del tiempo de ciclo de decisión (horas)	
		N.° de alternativas evaluadas automáticamente	

Artículo [40] — Big data analytics in operations management

Choi, T.M.; Wallace, S.W. y Wang, Y. (2018) — *Production and Operations Management*, Q1 · JIF 4.60

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Analítica de Big Data en Gestión de Operaciones	Capacidades de los datos disponibles	Volumen de datos de operaciones (TB)	Revisión de literatura operacional (POM, MSOM) Modelos de optimización (Python: Scipy, PuLP) Análisis de series temporales (SARIMA, Prophet) Simulación de cadena de suministro
		Velocidad de actualización de datos (lotes/hora)	
		Variedad y fuentes de datos integradas (n.º)	
	Modelos analíticos aplicados a operaciones	Modelos de optimización de inventario (LP, MIP)	
		Modelos de pronóstico de demanda (ARIMA, ML)	
		Modelos de gestión de la cadena de suministro	
Variable dependiente: Desempeño de la Gestión de Operaciones	Eficiencia de la cadena de suministro	Reducción de costos de inventario (%)	Revisión de literatura operacional (POM, MSOM) Modelos de optimización (Python: Scipy, PuLP) Análisis de series temporales (SARIMA, Prophet) Simulación de cadena de suministro
		Mejora del nivel de servicio (fill rate %)	
		Reducción del tiempo de ciclo operativo (%)	
	Capacidad de respuesta al mercado	Tiempo de respuesta a variaciones de demanda (días)	
		Tasa de fulfillment de pedidos (%)	
		N.º de quiebres de stock evitados por período	

Artículo [41] — AI lifecycle models need to be revised: An exploratory study in Fintech

Haakman, M. et al. (2021) — *Empirical Software Engineering*, Q1 · JIF 3.50

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Ciclo de Vida del Modelo de IA — CRISP-ML(Q)	Fases del ciclo de vida ML	Comprensión del negocio y de los datos	CRISP-ML(Q) framework de calidad MLflow para versionado y registro de experimentos Entrevistas a equipos de ML en Fintech (n=17 entrevistados) Análisis temático cualitativo (codificación inductiva)
		Preparación y transformación de datos	
		Modelado, entrenamiento y selección	
		Evaluación y validación del modelo	
		Despliegue y monitoreo en producción	
	Métricas de calidad por fase del ciclo	Compleitud de datos mínima requerida (%)	
		Accuracy mínimo aceptable por el negocio (threshold)	
		Frecuencia de reentrenamiento necesario (días)	
	Prácticas de MLOps adoptadas	N.º de experimentos registrados con trazabilidad	
		Versionado de modelos (MLflow / DVC)	

		Automatización del pipeline CI/CD ML (%)	
Variable dependiente: Calidad y Madurez del Sistema de ML en Producción	Calidad del modelo en producción	Data drift detectado (delta de accuracy)	CRISP-ML(Q) framework de calidad MLflow para versionado y registro de experimentos Entrevistas a equipos de ML en Fintech (n=17 entrevistados) Análisis temático cualitativo (codificación inductiva)
		F1-score en producción vs. F1-score en evaluación	
		N.º de reentrenamientos necesarios por mes	
	Madurez del proceso de desarrollo ML	Nivel de madurez MLOps alcanzado (escala 1–5)	
		N.º de fases con criterios de calidad definidos formalmente	
		Esfuerzo de mantenimiento del sistema (horas/mes)	

Artículo [42] — Information technology and organizational performance: An integrative model of IT business value

Melville, N.; Kraemer, K. y Gurbaxani, V. (2004) — MIS Quarterly, Q1 · JIF 12.50

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Inversión y Capacidades en Tecnología de Información (TI)	Recursos tecnológicos de TI	Inversión en TI (S/. por año)	Modelo conceptual integrador (meta-análisis de literatura) Revisión de 200+ estudios (1985–2003) Regresión múltiple jerárquica Encuesta a organizaciones Fortune 500 (EE.UU.)
		N.º de sistemas de información implementados	
		Capacidad de infraestructura tecnológica (escala)	
	Capacidades humanas en TI	Nivel de competencias digitales del personal (escala 1–5)	
		N.º de personal dedicado a TI	
		Horas de capacitación en TI por empleado/año	
	Recursos organizacionales complementarios	Madurez de los procesos de negocio (escala)	
		Cultura organizacional orientada a datos (escala)	
		N.º de socios tecnológicos estratégicos	
Variable dependiente: Desempeño Organizacional Impulsado por TI	Desempeño de los procesos internos	Eficiencia de procesos mejorada (%)	Modelo conceptual integrador (meta-análisis de literatura) Revisión de 200+ estudios (1985–2003) Regresión múltiple jerárquica Encuesta a organizaciones Fortune 500 (EE.UU.)
		Reducción de tiempos de ciclo (%)	
		Reducción de costos operativos (%)	
	Desempeño competitivo en el mercado	Crecimiento de ingresos (%)	
		Cuota de mercado ganada (%)	
		ROI de la inversión en TI (%)	